

# Přednáška 7: Bilineární model a bayesovský přístup k maticové dekompozici (odhad počtu komponent?)

Ondřej Tichý

Bayesovské metody v machine learningu (BML)

April 8, 2018

# Obsah přednášky

- ▶ bilineární model jako maticová dekompozice
- ▶ pár motivačních příkladů využití
- ▶ klasické možnosti řešení dekompozice
- ▶ bayesovská formulace maticové dekompozice
  - ▶ odhad počtu komponent
  - ▶ meze neurčitosti odhadů
- ▶ další předpoklady

# Bilineární model

Co to je?

► linearita v 1D:

ano  $f(x) = 4x + 7$

ne  $f(x) = 4x^2 + 7$

ne  $f(x) = \sin x + 7$

► bilinearita ve 2D (lineární v každé proměnné):

ano  $f(x, y) = 4xy + 7y + 3$

ano  $f(x, y) = 3x + 5y + 9$

ne  $f(x, y) = xy^2 + x + 7$

# Bilineární model

## Maticová formulace

- ▶ v maticové formulaci nás bude zajímat bilineární model

$$D = AX^T, \quad (1)$$


kde  $D \in \mathbf{R}^{p \times n}$ ,  $A \in \mathbf{R}^{p \times r}$  a  $X \in \mathbf{R}^{n \times r}$ .

- ▶  $r$  je vnitřní rozměr maticového součinu

# Motivace

K čemu je to dobré?


## ► astronomie - spektroskopie



# Motivace

K čemu je to dobré?

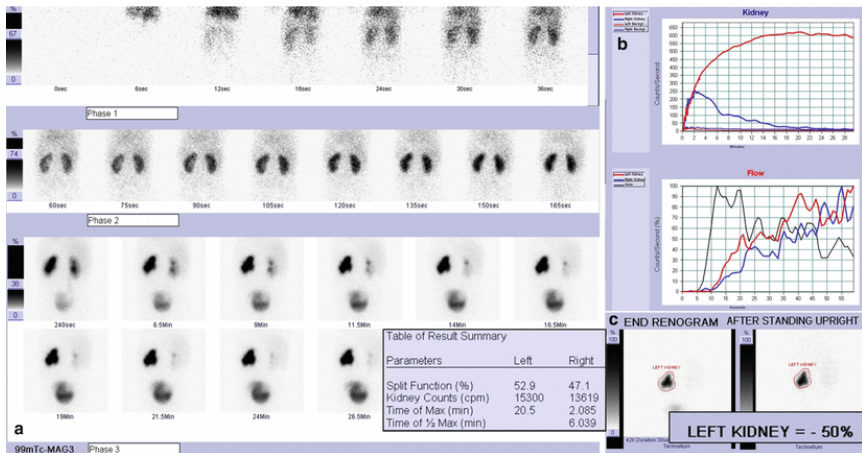
## ► hyperspektrální snímkování



# Motivace

K čemu je to dobré?

## ► nukleární medicína



## ► zpracování textu, zpracování řeči, komprese, a další

# Formulace modelu

## Reprezentace “obrázků”

- ▶ sloupce matice  $X$  představují váhové vektory (např. aktivitu zdroje v daném čase)
- ▶ sloupce matice  $A$  představují (např.) zdrojové obrázky uložené ve sloupcích:

$$\begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix} \rightarrow \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \end{pmatrix} \quad (2)$$



# Formulace modelu

## Maticová formulace

- ▶ každý obrázek (sloupec matic  $D$ )  $\mathbf{d}_t$  je lineární kombinace jednotlivých zdrojových obrázků:

$$\mathbf{d}_t = \mathbf{a}_1 x_{1,t} + \mathbf{a}_2 x_{2,t} + \cdots + \mathbf{a}_r x_{r,t} \quad (3)$$

- ▶ měřená data:  $D = [\mathbf{d}_1, \dots, \mathbf{d}_t, \dots, \mathbf{d}_n]$
  - ▶ zdrojové obrázky:  $A = [\mathbf{a}_1, \dots, \mathbf{a}_r]$
  - ▶ váhy zdrojových obrázků:  $X = [\mathbf{x}_1^T, \dots, \mathbf{x}_t^T, \dots, \mathbf{x}_n^T]^T$
- ▶ maticový zápis:

$$D = AX^T. \quad (4)$$

pozn.:  $D_{i,j} = \sum_{k=1}^r A_{i,k} X_{k,j}$

# Formulace modelu

## Předpoklady a neznalosti


- ▶ neznámý počet zdrojů  $r$
- ▶ pozitivita (často)
- ▶ šum
- ▶ rotační neurčitost

$$\hat{A}\hat{X}^T = \underbrace{\hat{A}R}_{\tilde{A}} \underbrace{R^{-1}\hat{X}^T}_{\tilde{X}} \quad (5)$$




# Cvičná data

Simulované hodnoty

Zdroj 1




Zdroj 2



# Cvičná data

## Data


- vynásobíme  $AX^T$  a přidáme šum:



# Cvičná data

## Data

- ▶ matice  $D$



# Souvislost s PCA

## PCA a SVD

- ▶ hledáme projekci  $A = DU$ , kde  $U$  je matice vlastních vektorů kovarianční matice  $C_D = \frac{1}{2} \sum (d_i - \bar{d})(d_i - \bar{d})^T$ , tzn.  $C_D = U\Lambda U^T$ .
- ▶ defacto hledáme souřadnou soustavu, ve které je variance jednotlivých komponent maximalizována
- ▶ SVD (singular value decomposition) přístup:


$$D = USV^T = \underbrace{US}_A \underbrace{V^T}_{X^T}, \quad (6)$$

$$\begin{array}{c} \mathbf{M} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^* \\ m \times n \quad m \times m \quad m \times n \quad n \times n \end{array}$$
$$\begin{array}{c} \mathbf{U} \quad \mathbf{U}^* = \mathbf{I}_m \\ \mathbf{V} \quad \mathbf{V}^* = \mathbf{I}_n \end{array}$$


# Souvislost s PCA

## Cvičný příklad





Zdroj 1



Zdroj 2



Zdroj 3



# Souvislost s PCA

## Poznámky

- ▶ velmi rychlé
- ▶ neřekne nám “správný” počet komponent
- ▶ šum a pozitivita
- ▶ rotační neurčitost



# Non-negative matrix factorization (NMF)

Ještě bez obtěžování pana Bayese...

- ▶ hledáme rozklad datové matice  $D$  jako

$$D \approx AX^T \quad (7)$$

- ▶ minimalizujeme vzdálenost levé a pravé strany rovnice

$$\min \|D - AX^T\|_2^2, \quad (8)$$

kde  $\|B - C\|_2^2 = \sum_{i,j} (B_{i,j} - C_{i,j})^2$ .

- ▶ problém je konvexní buď v  $A$  nebo  $X$ , nikoliv v obou najednou  
 $\Rightarrow$  nelze očekávat nalezení globálního minima.
- ▶ široká škála numerických metod pro řešení (gradient descent, konjugované gradienty, atd.)
- ▶ kompromis: “multiplicative update rules”, Lee and Seung 2001 (verze, kterou si ukážeme)

# Non-negative matrix factorization (NMF)

## Algoritmus

- ▶ inicializace  $A$  a  $X$
- ▶ iterujeme

$$X^T \leftarrow X^T \circ \left( (A^T D) \oslash (A^T A X^T) \right) \quad (9)$$

$$A \leftarrow A \circ \left( (DX) \oslash (A X^T X) \right) \quad (10)$$

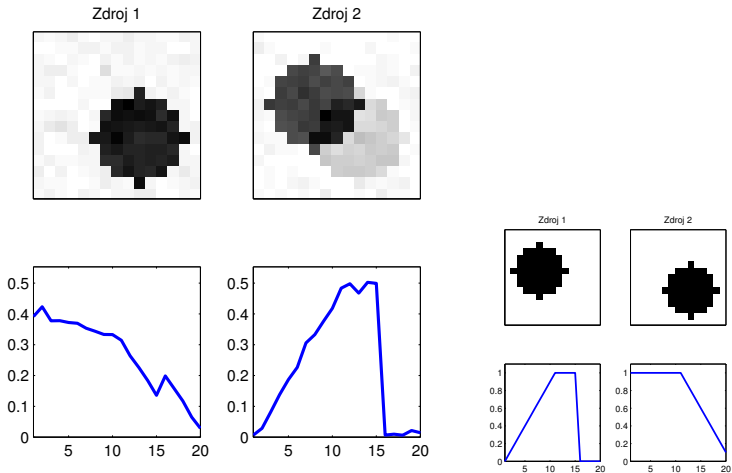
kde  $\circ$  je násobení “po prvcích” a  $\oslash$  je dělení “po prvcích”.

- ▶ máme výsledné odhady  $\hat{A}$  a  $\hat{X}$

# Non-negative matrix factorization (NMF)

## Cvičný příklad


- ▶ start z náhodně vygenerovaných matic
- ▶  $r = 2$



# Non-negative matrix factorization (NMF)

## Cvičný příklad

- ▶ start z náhodně vygenerovaných matic
- ▶  $r = 3$



# Non-negative matrix factorization (NMF)

## Hlavní (ne)výhody

- ▶ velice jednoduché na implementaci
- ▶ velice rychlé na výpočet
- ▶ máme pouze bodový odhad  $A$  a  $X$
- ▶ výsledek silně závisí na počtu komponent
- ▶ stále rotační neurčitost, výsledek je nejednoznačný

# Matematická vsuvka

## Diagonála, stopa, Kronekerův součin

- ▶ operátor diagonály,  $\text{diag}()$ :

$$\text{diag} \left( \left( \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \right) \right) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix} \quad (11)$$

$$\text{diag} \left( \left( \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix} \right) \right) = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \quad (12)$$

- ▶ operátor stopa, součet diagonálních prvků čtvercové matice,  $\text{tr}()$ :

$$\text{tr}(A) = \sum_i A_{i,i} \quad (13)$$

- ▶ pro rozměrově kompatibilní matice platí:

$$\text{tr}(ABC) = \text{tr}(CAB) \quad (14)$$

# Matematická vsuvka

Diagonála, stopa, Kronekerův součin

- Kronekerův součin dvou matic:

$$A \otimes B = \begin{pmatrix} a_{11}B & a_{12}B & \cdots & a_{1m}B \\ a_{21}B & a_{22}B & & \vdots \\ \vdots & & \ddots & \vdots \\ a_{n1}B & \cdots & \cdots & a_{nm}B \end{pmatrix} \quad (15)$$

# Matematická vsuvka

## Maticové normální rozdělení

- ▶ maticové normální rozdělení matice  $A \in \mathbf{R}^{p \times r}$ :

$$\mathcal{N}_A(\mu_A, \Sigma_p \otimes \Phi_r) = \frac{1}{(2\pi)^{\frac{pr}{2}} |\Sigma_p|^{\frac{r}{2}} |\Phi_r|^{\frac{p}{2}}} \times \\ \times \exp \left( -\frac{1}{2} \text{tr} \left[ \Sigma_p^{-1} (A - \mu_A) (\Phi_r^{-1})^T (A - \mu_A)^T \right] \right), \quad (16)$$

- ▶ jeho momenty:

$$\widehat{A} = \mu_A, \quad (17)$$

$$\widehat{AA^T} = \text{tr}(\Phi_r) \Sigma_p + \mu_A \mu_A^T, \quad (18)$$

$$\widehat{A^T A} = \text{tr}(\Sigma_p) \Phi_r + \mu_A^T \mu_A. \quad (19)$$



# Bayesovská formulace

Variační PCA [Bishop, 1999]

- ▶ model pozorování

$$D = AX^T + E, \quad (20)$$

kde  $E_{i,j} = \mathcal{N}(0, \omega^{-1})$ ,  $\forall i, \forall j$ .

- ▶ model dat

$$f(D|A, X, \omega) = \mathcal{N}\left(AX^T, \omega^{-1}I_p \otimes I_n\right), \quad (21)$$

kde  $\omega$  je (neznámá) variance šumu s apriorním modelem

$$f(\omega) = \mathcal{G}(\vartheta_0, \rho_0). \quad (22)$$

# Bayesovská formulace

Variační PCA [Bishop, 1999]

- ▶ předpokládejme známé (zvolené)  $r$
- ▶ apriorní modely pro  $A$  a  $X$  jsou voleny jako

$$f(A) = \mathcal{N}(\mathbf{0}, I_p \otimes I_r) \quad (23)$$

a

$$f(X) = \mathcal{N}(\mathbf{0}, I_n \otimes I_r). \quad (24)$$

# Opakování

## Variační Bayesova aproximace

- ▶ máme model dat  $f(\mathbf{y}|\theta)$ ,
- ▶ máme  $q$  podmíněně nezávislých proměnných, tzn. pro jejich arpiorna platí

$$f(\theta_1, \theta_2, \dots, \theta_q) = \prod_{i=1}^q f(\theta_i), \quad (25)$$

- ▶ pak aposteriorní rozdělení  $\tilde{f}(\theta_i|\mathbf{y})$  pro  $i$ tý parametr získáme VB aproximací jako

$$\tilde{f}(\theta_i|\mathbf{y}) \propto \exp \left[ E_{\tilde{f}(\theta_{\setminus i}|\mathbf{y})} (\ln f(\theta_1, \theta_2, \dots, \theta_q, \mathbf{y})) \right], \quad \forall i. \quad (26)$$

# Variační PCA

## Řešení

- ▶ odhad variance šumu:  $\tilde{f}(\omega|D, r) = \mathcal{G}_\omega(\vartheta, \rho)$ , kde

$$\vartheta = \vartheta_0 + \frac{n\rho}{2}, \quad (27)$$

$$\rho = \rho_0 + \frac{1}{2} \text{tr} \left( DD^T - \widehat{A} \widehat{X}^T D^T - D \widehat{X} \widehat{A}^T \right) + \frac{1}{2} \text{tr} \left( \widehat{A}^T \widehat{A} \widehat{X}^T \widehat{X} \right) \quad (28)$$

s momentem  $\widehat{\omega} = \frac{\vartheta}{\rho}$ .

- ▶ odhad matice  $A$ :  $\tilde{f}(A|D, r) = \mathcal{N}_A(\mu_A, I_p \otimes \Sigma_A)$ , kde

$$\Sigma_A = \left( \widehat{\omega} \widehat{X}^T \widehat{X} + I_r \right)^{-1}, \quad \mu_A = \widehat{\omega} D \widehat{X} \Sigma_A. \quad (29)$$


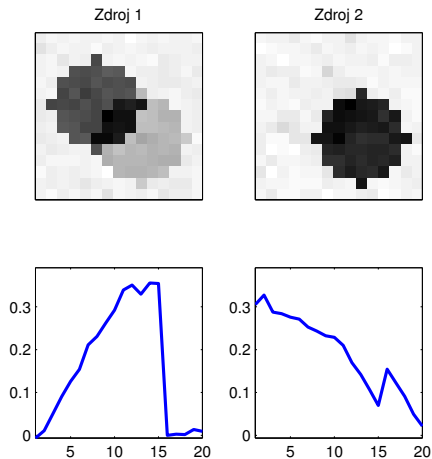
- ▶ odhad matice  $X$ :  $\tilde{f}(X|D, r) = \mathcal{N}_X(\mu_X, I_n \otimes \Sigma_X)$ , kde

$$\Sigma_X = \left( \widehat{\omega} \widehat{A}^T \widehat{A} + I_r \right)^{-1}, \quad \mu_X = \widehat{\omega} D^T \widehat{A} \Sigma_X. \quad (30)$$

# Variační PCA

## Cvičný příklad


- ukážeme si případ pro  $r = 2$  a  $r = 3$ :




# Variační PCA

## Cvičný příklad





Zdroj 1



Zdroj 2



Zdroj 3




# Variační PCA s pozitivitou

## Pozitivita

- ▶ ořezané normální rozdělení:

- ▶ místo  $\mathcal{N}(\mu, \sigma)$  můžeme použít  $t\mathcal{N}(\mu, \sigma, [0, \infty])$

$$t\mathcal{N}_x(\mu, \sigma, [0, \infty]) \propto \mathcal{N}_x(\mu, \sigma)\chi(x > 0) \quad (31)$$



- ▶ v našem případě:


$$f(A) = t\mathcal{N}_A(\mathbf{0}, I_p \otimes I_r, [0, \infty]) \quad (32)$$

$$f(X) = t\mathcal{N}_X(\mathbf{0}, I_n \otimes I_r, [0, \infty]) \quad (33)$$


# Variační PCA s pozitivitou

## Cvičný příklad

Zdroj 1



Zdroj 2



Zdroj 3

